

Venta de televisores

Miguel Salas

2022-12-04

#Introducción

Las series de tiempo nos ayudan a analizar el comportamiento de las variables a través del tiempo. De esta manera, con un análisis más profundo podemos evaluar cómo se comportará en el futuro. Para este caso utilizamos una base de datos de ventas por trimestre, con el objetivo de hacer el análisis pertinente y visualizar cómo se comportará la variable y hacer pronósticos del mismo.

```
#Load xlsx package
library("readxl")

df <- read_excel("Ventas.xlsx")
df
```

```
## # A tibble: 16 x 2
##   Trimestre Ventas
##   <dbl>   <dbl>
## 1      11     4.8
## 2      12     4.1
## 3      13      6
## 4      14     6.5
## 5      21     5.8
## 6      22     5.2
## 7      23     6.8
## 8      24     7.4
## 9      31      6
## 10     32     5.6
## 11     33     7.5
## 12     34     7.8
## 13     41     6.3
## 14     42     5.9
## 15     43      8
## 16     44     8.4
```


Podemos observar la base de datos donde el primer dígito de la columna Trimestre corresponde al año y el segundo al trimestre, con la correspondiente venta de ese trimestre.

```
ventas <- c(4.8, 4.1, 6, 6.5, 5.8, 5.2, 6.8, 7.4, 6, 5.6, 7.5, 7.8, 6.3, 5.9, 8, 8.4)
t = 1:16
```

Como se puede observar las ventas tienen una tendencia lineal positiva, donde hay ciclos a la alta y ciclos a la baja, sin embargo, al largo plazo siempre termina siguiendo una tendencia lineal positiva. Por lo que el alto más alto del próximo año siempre es mayor que el alto más alto del ciclo anterior. Lo mismo ocurre con el bajo más bajo.


```
plot(t, ventas, type = "o", col = "red", main = "Ventas trimestre")
```

Ventas trimestre



En el modelo lineal con la fórmula `ventas ~ tiempo`, podemos realizar el análisis predictivo que nos ayudará a determinar las ventas a futuro. El coeficiente resultó 4.85.


```
N = lm(ventas~t)
plot(t, ventas, type= "l", col = "red")
abline(N, col = "blue")
```



N


##

```
## Call:
## lm(formula = ventas ~ t)
##
## Coefficients:
## (Intercept)          t
##      4.8525      0.1799
x= ts(ventas, frequency = 4, start=c(2016,1))
plot.ts(x, col = "red")
```



```
T = decompose(x)
plot(T, col = "blue")
```

Decomposition of additive time series



Descomponiendo la serie del tiempo podemos identificar cuatro componentes de la serie de tiempo. El primero es el valor observado, el segundo la tendencia, el tercero la varicación estacional y el último variación irregularidad.

T\$seasonal


```
##          Qtr1      Qtr2      Qtr3      Qtr4
## 1 -0.4395833 -1.0687500  0.5895833  0.9187500
## 2 -0.4395833 -1.0687500  0.5895833  0.9187500
## 3 -0.4395833 -1.0687500  0.5895833  0.9187500
## 4 -0.4395833 -1.0687500  0.5895833  0.9187500
```

#Ventas desestacionalizadas y regresión

```
ventas_desestacionalizadas = (T$x)/(T$seasonal)
x3 = 1:16
y3 = ventas_desestacionalizadas
N3 = lm(y3~x3)
N3
```

```
##
## Call:
## lm(formula = y3 ~ x3)
##
## Coefficients:
## (Intercept)          x3
##    -3.5443      0.4847
```

```
plot(x3, y3, type = "l")
abline(N3, col = "red")
text(6, 7,)
```



Pronóstico de ventas para el siguiente año.

```
f = function(x) {4.8525 + 0.1799*x}
# Los índices estacionales son:
a1 = T$seasonal[1]
a2 = T$seasonal[2]
a3 = T$seasonal[3]
a4 = T$seasonal[4];
f(17)*a1*1000

## [1] -3477.456
f(18)*a2*1000

## [1] -8646.936
f(19)*a3*1000

## [1] 4876.208
f(20)*a4*1000

## [1] 7763.897
T=ts(ventas, frequency = 4, start=c(2016, 1))
T

##   Qtr1 Qtr2 Qtr3 Qtr4
## 1  4.8  4.1  6.0  6.5
## 2  5.8  5.2  6.8  7.4
## 3  6.0  5.6  7.5  7.8
## 4  6.3  5.9  8.0  8.4
D =decompose(T, type = "m") ##"m"
D

## $x
##   Qtr1 Qtr2 Qtr3 Qtr4
```

```

## 1  4.8  4.1  6.0  6.5
## 2  5.8  5.2  6.8  7.4
## 3  6.0  5.6  7.5  7.8
## 4  6.3  5.9  8.0  8.4
##
## $seasonal
##      Qtr1      Qtr2      Qtr3      Qtr4
## 1 0.9306617 0.8363763 1.0915441 1.1414179
## 2 0.9306617 0.8363763 1.0915441 1.1414179
## 3 0.9306617 0.8363763 1.0915441 1.1414179
## 4 0.9306617 0.8363763 1.0915441 1.1414179
##
## $trend
##      Qtr1      Qtr2      Qtr3      Qtr4
## 1      NA      NA 5.4750 5.7375
## 2 5.9750 6.1875 6.3250 6.4000
## 3 6.5375 6.6750 6.7625 6.8375
## 4 6.9375 7.0750      NA      NA
##
## $random
##      Qtr1      Qtr2      Qtr3      Qtr4
## 1      NA      NA 1.0039818 0.9925353
## 2 1.0430335 1.0048157 0.9849340 1.0129944
## 3 0.9861607 1.0030787 1.0160445 0.9994305
## 4 0.9757661 0.9970658      NA      NA
##
## $figure
## [1] 0.9306617 0.8363763 1.0915441 1.1414179
##
## $type
## [1] "multiplicative"
##
## attr("class")
## [1] "decomposed.ts"
CME2=mean(ventas)
CME2

## [1] 6.38125

```

#Conclusión

Como se pudo observar, las series de tiempo son de gran ayuda para hacer predicciones y un análisis que nos permita identificar el comportamiento de las variables. Con esto sería posible realizar un plan de acción de acuerdo a ventas futuras. Por lo que las aplicaciones de las series de tiempo son de gran utilidad para un negocio y las aplicaciones en el mundo son diversas.